

Livrable final

AI Deployment - veille OSINT militaire
NER, Elasticsearch et dashboards analytiques

Périmètre : Corpus TASS, extraction d'entités militaires, indexation et visualisation.

Dataset : 20 895 articles publiés entre 2015 et 2025.

Stack : Python, spaCy NER, Elasticsearch et Kibana.

Dépôt GitHub : github.com/edcdataworker/ai-deployment-osint

Ce que montre le corpus

Le dispositif transforme un corpus d'articles en indicateurs interrogeables. Le modèle NER classe les mentions en trois catégories opérationnelles - WEAPON, MIL_UNIT et MIL_ORG - puis Elasticsearch agrège les résultats dans Kibana. Les tableaux de bord rendent visibles le volume, la temporalité, la concentration des entités et la distribution par article.

Armes

41 665

Soit 31,2 % des mentions d'entités et 1,99 mention par article en moyenne.

Unités

19 116

Soit 14,3 % des mentions et 0,91 mention par article en moyenne.

Organisations

72 816

Soit 54,5 % des mentions et 3,49 mentions par article en moyenne.

Constats clés

- Forte domination des organisations. Plus d'une mention d'entité sur deux relève de MIL_ORG, ce qui reflète un cadrage institutionnel très présent dans les dépêches.
- Concentration des systèmes d'armes. S-400 domine nettement le classement ; le premier élément est plus de deux fois au-dessus du suivant dans la capture.
- Pic de production en 2023. Le volume annuel d'articles atteint son maximum visible autour de 4 400, avant de refluer en 2024-2025.
- Distribution très asymétrique. Beaucoup d'articles ne citent aucune arme ; une minorité en cite un grand nombre, jusqu'à près de 40.

Précaution : ces métriques décrivent les mentions produites par TASS. Elles ne mesurent ni l'emploi réel d'un équipement, ni l'ordre de bataille, ni la véracité des affirmations.


Sources, code et méthode

Accès au code

Dépôt GitHub du projet
<https://github.com/edcdataworker/ai-deployment-osint>

Notebook Colab - [ouvrir le notebook de travail](#). Le dépôt contient le livrable, son générateur et les captures.

Pipeline fonctionnel



Choix d'architecture. Un NER spécialisé offre une inférence locale, rapide, déterministe et structurée. Elasticsearch déporte les agrégations côté serveur ; Kibana permet de composer les vues sans recoder l'analyse. Cette séparation facilite la traçabilité : article source, entités détectées, index et visualisation restent auditables.

Volumes, temporalité et structure des entités



Lecture des métriques

- 133 597 mentions d'entités sont extraites des 20 895 articles, soit 6,39 mentions par article en moyenne.
- MIL_ORG est majoritaire (54,5 %), devant WEAPON (31,2 %) et MIL_UNIT (14,3 %). La tarte donne immédiatement la structure du corpus.
- La série annuelle contextualise les volumes. Elle augmente de 520 articles en 2015 à un sommet proche de 4 400 en 2023, puis décroît.
- Le filtre temporel global rend tous les indicateurs cohérents et permet une comparaison de périodes sans multiplier les tableaux.

Pourquoi cette vue ?

Elle répond en quelques secondes à trois questions : combien d'articles, combien d'entités et comment la couverture évolue-t-elle ?

Point de vigilance

Une hausse de volume éditorial augmente mécaniquement les mentions. Pour mesurer l'intensité, il faut aussi normaliser par article.

Entités dominantes et asymétrie du corpus



Interprétation

- S-400 domine les systèmes d'armes avec environ 1 800 mentions visibles, très loin devant le deuxième terme. Cette concentration justifie un suivi spécifique dans le temps.
- Northern Fleet arrive en tête des unités avec environ 1 550 mentions. Le classement décroît ensuite régulièrement, ce qui signale un noyau restreint d'unités très médiatisées.
- Russian Defense Ministry domine les organisations avec plus de 5 000 mentions. Ce résultat est cohérent avec la nature institutionnelle et étatique de la source.
- La distribution du nombre d'armes par article est fortement inclinée. Le mode est à zéro ; la moyenne de 1,99 est tirée vers le haut par une longue traîne d'articles très chargés.

Choix de dashboard : les barres horizontales conviennent aux libellés longs et rendent le rang évident. L'histogramme complète les tops : il montre la forme de la population et évite de confondre quelques articles extrêmes avec le comportement typique.

Table de synthèse par année

■ Entités détectées par année

⬇ Exporter

Année	Articles	Armes	Unités	Orgs
2015	520	1,528	512	2,238
2016	1,174	2,633	1,131	4,514
2017	1,628	3,777	1,255	6,079
2018	1,452	3,543	1,179	5,367
2019	1,890	5,860	2,083	6,794
	20,895	41,665	19,116	72,816

Lignes par page: 12

< 1 >

Ratios calculés sur les lignes visibles

Année	Armes/article	Unités/article	Orgs/article
2015	2,94	0,98	4,30
2016	2,24	0,96	3,84
2017	2,32	0,77	3,73
2018	2,44	0,81	3,70
2019	3,10	1,10	3,59
Corpus complet	1,99	0,91	3,49

Ce que les ratios ajoutent

- Les volumes bruts répondent à « combien ? » ; les ratios répondent à « avec quelle densité éditoriale ? ».
- 2019 combine, sur les lignes visibles, la plus forte densité d'armes (3,10) et d'unités (1,10) par article.
- La baisse des organisations par article de 2015 à 2019 peut refléter un changement de cadrage, mais elle doit être testée sur toute la période.
- Le tableau est aussi un contrôle qualité : une année absente, un ratio aberrant ou une rupture brutale devient immédiatement détectable.

Note : la capture pagine les années ; seules les lignes 2015-2019 et le total sont visibles. Les ratios ci-dessus sont calculés à partir de ces valeurs affichées, sans extrapolation des années masquées.

Pourquoi ces dashboards sont utiles

Vue	Question traitée	Décision facilitée	Limite principale
KPI globaux	Quel est le volume traité ?	Vérifier couverture et ingestion	Les comptes ne mesurent pas la qualité
Série annuelle	Quand la couverture change-t-elle ?	Isoler les périodes à examiner	Effet volume de publication
Donut par label	Quel type d'entité domine ?	Comprendre le cadrage du corpus	Dépend du schéma d'annotation
Top entités	Qui ou quoi est le plus cité ?	Prioriser les investigations	Biais vers les variantes fréquentes
Distribution/article	Quelle est la forme des détections ?	Repérer zéros et valeurs extrêmes	Ne dit rien sur la pertinence
Table annuelle	Les totaux sont-ils cohérents ?	Auditer et exporter	Pagination dans la capture

Améliorations recommandées

- Normaliser chaque série en mentions pour 100 articles afin de séparer activité éditoriale et intensité lexicale.
- Ajouter un indicateur de qualité NER sur le jeu dev : précision, rappel, F1 par label et matrice de confusion.
- Normaliser les alias (sigles, translittérations, variantes) avant les agrégations pour éviter la fragmentation des tops.
- Créer une vue de co-occurrence WEAPON x MIL_UNIT et un drill-down vers les articles sources pour validation analyste.
- Afficher la couverture et la date de collecte afin d'éviter de lire une année partielle comme une baisse opérationnelle.

Critère de réussite

Un bon dashboard n'est pas seulement lisible : chaque agrégation doit permettre de revenir au texte source, de vérifier une détection et de distinguer fréquence médiatique, qualité du modèle et réalité opérationnelle.

TASS : cadrage militaire dominant et pic éditorial en 2023

Appréciation

Le corpus fait apparaître une communication fortement institutionnelle, structurée autour d'un petit nombre d'organisations et de systèmes d'armes très cités. Le volume d'articles culmine en 2023, tandis que les organisations représentent 54,5 % de toutes les mentions d'entités.

Éléments observés

- 20 895 articles couvrent la période 2015-2025 ; 133 597 mentions d'entités sont détectées.
- Russian Defense Ministry domine le classement des organisations ; S-400 domine celui des armes ; Northern Fleet celui des unités.
- La distribution des armes par article est très asymétrique : de nombreux zéros coexistent avec une longue traîne.

Analyse

- La prépondérance des organisations est compatible avec une production de dépêches centrée sur les annonces officielles, les porte-parole et les institutions militaires.
- La surreprésentation d'un système comme S-400 peut signaler une priorité narrative ou diplomatique autant qu'un intérêt opérationnel.
- Le pic de 2023 indique une intensification de la couverture ; il ne suffit pas, seul, à conclure à une intensification militaire.

Niveau de confiance

- Modéré. Les constats quantitatifs sont directement visibles dans les dashboards. L'interprétation reste limitée par le biais éditorial de TASS, la qualité non documentée du NER et l'absence de triangulation avec d'autres sources.

Indicateurs à surveiller

- Rupture de tendance des mentions normalisées par article ; apparition d'une nouvelle arme ou unité dans le top 20 ; hausse de co-occurrences arme-unité ; divergence entre TASS et sources indépendantes.

Jugement analytique : les dashboards constituent un outil de veille et de détection de signaux. Toute conclusion opérationnelle doit être confirmée par lecture des articles, contrôle du modèle et confrontation à des sources distinctes.

Un dispositif utile, à condition de rester auditable

Source

TASS est un média d'État russe. Les thèmes, omissions, cadrages et volumes relèvent d'une ligne éditoriale.

Modèle

Sans précision, rappel et F1 sur un jeu dev validé, un volume de détections ne prouve pas la qualité du NER.

Comptage

Une mention n'est ni une entité unique, ni un événement. Les répétitions dans un même article peuvent gonfler les totaux.

Temporalité

Une année partielle ou un changement de collecte peut produire une rupture artificielle dans la série.

Normalisation

Les alias et variantes linguistiques peuvent fragmenter une même entité en plusieurs barres.

Interprétation

Les tops mesurent la visibilité dans la source, pas l'importance opérationnelle réelle.

Conclusion

La chaîne proposée répond au besoin du TP : elle convertit un corpus brut en objets structurés, indexables et exploitables. Les trois dashboards couvrent les niveaux complémentaires de l'analyse : vue d'ensemble, classement des entités et contrôle temporel. Les résultats mettent en évidence un corpus dominé par les organisations, un pic d'activité éditoriale en 2023 et une forte concentration de certaines entités. La valeur du dispositif tient surtout à sa capacité de filtrage et de retour au document source ; son usage renseignement doit rester prudent, traçable et triangulé.

Livrable conforme aux éléments de la page 21

1. lien vers le code fourni ; 2. trois captures de dashboards ; 3. analyse des métriques et justification des vues ; 4. note de renseignement courte.

Dépôt du projet : <https://github.com/edcdataworker/ai-deployment-osint>. Le notebook Colab reste référencé dans le README.