
Livable

AI Deployment

Auteurs :

Jean-Christophe DORN

Noah SEGONDS

Edouard CAPPAERT

Enseignant :

Matthieu LARBOULLET

1. Introduction	3
1.1. Contexte	3
1.2. Problématique	3
2. Pipeline technique	4
3. Lien du code source	4
4. Screenshots des dashboards Kibana	5
4.1. KPIs globaux, évolution temporelle et répartition par label	5
4.2. Top systèmes d'armes, unités, organisations et distribution	5
4.3. Tableau des entités par année (2015–2025)	6
5. Analyse des métriques et choix de dashboards	7
5.1. KPIs globaux	7
5.2. Évolution temporelle	7
5.3. Top systèmes d'armes	7
5.4. Top unités et organisations	7
5.5. Distribution par article	8
6. Note de renseignement	8

1.1. Contexte

L'agence de presse russe TASS constitue une source OSINT (Open Source Intelligence) majeure pour l'analyse du discours militaire officiel russe. Avec plus de 20 000 articles en anglais couvrant la période 2015–2025, ce corpus offre une fenêtre unique sur la communication institutionnelle des forces armées russes : acquisitions d'armements, mouvements de troupes, opérations déclarées.

Ce projet, réalisé dans le cadre du cours AI Deployment de l'Eugenia School, construit un pipeline NLP complet pour extraire et structurer automatiquement les entités militaires de ce corpus, puis les rendre exploitables via des dashboards analytiques Kibana.

1.2. Problématique

Comment automatiser l'extraction d'entités militaires nommées — armes, unités de combat, organisations — depuis un corpus de 21 000 articles de presse, afin de produire des données exploitables pour l'analyse du renseignement en sources ouvertes, sans recourir à une lecture manuelle article par article ?

Le pipeline suit 5 étapes enchaînées, de l'extraction des données brutes jusqu'aux dashboards Kibana :

Étape 1 — Extraction	Chargement et nettoyage du fichier data_set.json (21 742 articles TASS). Résultat : corpus.json — 21 676 articles valides. Script : step1_extract.py
Étape 2 — Annotation	Pré-annotation avec Claude Haiku (Anthropic). Le LLM retourne le texte exact des entités en JSON. Offsets calculés avec str.find() en Python. Approche human-in-the-loop. Script : step2_annotate.py
Étape 3 — Fine-tuning	Entraînement NER spaCy par transfer learning depuis en_core_web_sm. 40 exemples / 81 entités annotées. Split 80% train / 20% dev. Format DocBin. Résultat : F1=34%, Précision=45%, Rappel=28%. Script : step3_train.py
Étape 4 — Inférence	Application du modèle (output/model-best) sur les 21 676 articles. Post-filtrage des faux positifs par règles lexicales. Script : step4_infer.py
Étape 5 — Elasticsearch	Indexation dans Elasticsearch (index ner_osint). Champs keyword pour agrégations. Ingestion bulk. 6 dashboards Kibana. Script : step5_elasticsearch.py

3 labels détectés : WEAPON (armes, missiles, drones, chars, aéronefs) — MIL_UNIT (brigades, bataillons, flottes) — MIL_ORG (ministères, états-majors, commandements)

3.Lien du code source

Dépôt GitHub	https://github.com/edcdataworker/ai-deployment-osint
Notebook Google Colab	https://colab.research.google.com/drive/1wE2RMlx62lc95o7bkGo29yfDAV7svlRQ?usp=sharing
Dashboard Kibana	https://my-elasticsearch-project-aed731.kb.eu-west-1.aws.elastic.cloud/app/dashboards#/view/dash-tass-v3

Le dépôt GitHub centralise le livrable, les captures et le script de génération. Le notebook Colab contient l'intégralité du pipeline : extraction, annotation LLM, fine-tuning spaCy, inférence et ingestion Elasticsearch.

4.1. KPIs globaux, évolution temporelle et répartition par label



4.2. Top systèmes d'armes, unités militaires, organisations et distribution



4.3. Tableau des entités détectées par année (2015–2025)

Entités détectées par année

Exporter

Année	Articles	Armes	Unités	Orgs
2015	520	1,528	512	2,238
2016	1,174	2,633	1,131	4,514
2017	1,628	3,777	1,255	6,079
2018	1,452	3,543	1,179	5,367
2019	1,890	5,860	2,083	6,794
	20,895	41,665	19,116	72,816

Lignes par page: 12

5.1. KPIs globaux

20 895 Articles analysés	41 665 Armes (WEAPON)	19 116 Unités (MIL_UNIT)	72 816 Orgs (MIL_ORG)
------------------------------------	---------------------------------	------------------------------------	---------------------------------

Le corpus traité couvre 20 895 articles sur 2015–2025. Au total 133 597 entités ont été détectées. La dominance des MIL_ORG (72 816 — 54%) reflète le style journalistique de TASS : chaque article cite systématiquement sa source institutionnelle ("Russian Defense Ministry reported..."), ce qui gonfle mécaniquement cette catégorie.

5.2. Évolution temporelle — Articles publiés par année

L'histogramme révèle une augmentation significative du volume d'articles militaires TASS à partir de 2022, avec un pic en 2023 (~4 000 articles). Cette corrélation directe avec l'invasion de l'Ukraine en février 2022 valide la pertinence du corpus pour l'analyse OSINT.

5.3. Top systèmes d'armes (WEAPON)

Le système S-400 arrive en tête (~1 500 mentions), devant le Su-30SM et le Kinzhal. Ce classement reflète les axes stratégiques de la communication TASS : valorisation des systèmes export (S-400 vendu à l'Inde et la Turquie) et revendication de supériorité aérienne.

5.4. Top unités militaires et organisations

La Northern Fleet domine les unités (~1 400 mentions). Le Russian Defense Ministry totalise ~5 000 mentions côté organisations, quasi-présent dans chaque article comme source officielle.

5.5. Distribution du nombre d'armes par article

La distribution en queue lourde confirme que la majorité des articles contiennent 0 à 3 mentions d'armes, avec quelques articles techniques atteignant 20–30 mentions. Ce dashboard permet de cibler rapidement les articles à fort contenu militaire.

NOTE DE RENSEIGNEMENT — CORPUS TASS (2015–2025)

Objet : Analyse des tendances militaires russes identifiées par NER sur le corpus TASS

Source : TASS — Agence de presse d'État russe. Biais éditorial pro-Kremlin à prendre en compte.

1. Accélération de la communication militaire depuis 2022

Le volume d'articles militaires TASS augmente de 170% entre 2021 et 2023 (de ~1 500 à ~4 000 articles/an). Ce pic correspond à l'invasion de l'Ukraine et à l'intensification des opérations en 2023.

2. Priorité stratégique : défense anti-aérienne et aviation de combat

Le S-400 (1 500 mentions) et le Su-30SM dominent le classement des armes, reflétant la valorisation des systèmes export et la revendication de supériorité aérienne.

3. Domination de la Flotte du Nord dans le discours officiel

La Northern Fleet (1 400 mentions) dépasse la Black Sea Fleet pourtant directement impliquée dans le conflit ukrainien. TASS privilégie la communication sur les capacités stratégiques (sous-marins nucléaires, missiles balistiques).

4. Limites et précautions d'interprétation

- Source unique : les résultats reflètent le cadrage narratif TASS, pas une réalité terrain objective
- F1-score de 34% : les tendances générales sont fiables, les entités individuelles doivent être vérifiées
- Entités ukrainiennes absentes : elles n'apparaissent qu'en tant que cibles dans le corpus TASS

Ce pipeline constitue une démonstration de faisabilité OSINT. Pour un usage opérationnel, il conviendrait d'enrichir le corpus avec d'autres sources et d'augmenter les données d'entraînement à 500+ exemples annotés.